

Comparación de Aprendizaje entre jugadores y un Agente Inteligente en el juego Snake

Marco Ferraro Rodriguez

Gabriel Valentine Fonseca

Palabras claves—inteligencia artificial, agente inteligente, videojuego, aprendizaje automático, aprendizaje reforzado, Snake, Deep Q-Learning.

INTRODUCCIÓN

Los videojuegos en la actualidad forman parte de un gran porcentaje de personas las cuales exigen constantemente un mayor realismo e interacción en estos, estas interacciones se dan por general entre agentes, entornos de juego y personas, las cuales aportan problemas complejos para que los agentes los resuelvan. Por razones relacionadas a esas y que son entornos controlables y con cantidades infinitas de datos útiles para algoritmos de aprendizaje automático, es que es los videojuegos son un área de investigación perfecta para la inteligencia artificial [1], lo que ha llevado a realizar aportes como los personajes no controlados por jugadores o NPC, como son conocidos popularmente, los cuales han formado parte de una práctica esencial en esta área para aportar el extra de experiencia interactiva y realismo que tanto se solicita.

Estos NPCs han despertado gran curiosidad en los desarrolladores debido a la necesidad de crear mejores agentes en ambientes más complejos y ver hasta que punto pueden ser competentes con un ser humano, ya que, como menciona [2], por lo general los NPCs definen su comportamiento a base de scripts fijos con tareas básicas que un NPC puede hacer, lo que hace que tengan comportamientos inflexibles y rígidos, por lo que continuamente se han buscado técnicas para mejorar estos agentes de tal manera que empiecen con conocimientos desde cero al igual que una jugador y a partir de ahí se vayan desarrollando.

El incorporar estos agentes inteligentes requiere de algoritmos creados especialmente para ellos lo cual conlleva un enorme trabajo y mucho tiempo sin contar el hecho de que un gran número de estos algoritmos usan técnicas de aprendizaje automático que para lograr adaptarse a cada juego requieren de un lapso de duración bastante considerable. Esto lleva a buscar formas de agilizar estos procesos proponiendo, por ejemplo, el aprender de las acciones que realiza un jugador utilizando técnicas de aprendizaje reforzado en estos algoritmos [3].

Esta técnica de aprendizaje reforzado que se mencionó anteriormente es la más común en la industria de los videojuegos debido a que ofrece grandes resultados gracias a que permite aprovechar la gran cantidad de escenarios de datos utilizando algoritmos que permiten evaluar repetidamente cada uno de los escenarios de datos, obteniendo cada vez mejores resultados [4]. Un ejemplo del uso de esta técnica es la inteligencia

artificial de google Deep Mind que utilizando aprendizaje por refuerzo profundo ha conseguido crear un agente competitivo capaz de derrotar a jugadores profesionales del videojuego Starcraft, el cual posee una gran cantidad de variantes y complejidad.

Sin embargo, es importante dejar claro que el aprendizaje automático ofrece otra gran variedad de algoritmos diferentes aparte del ya mencionado, como lo son el aprendizaje supervisado, no supervisado, multi-tarea, entre otros. Estos además poseen capacidad de entrenar a los agentes inteligentes, por lo que la alternativa que desee utilizar el desarrollador va a depender del contexto para el cual esté siendo desarrollado este agente, los requisitos y las capacidades con las que deba contar dicho agente.

OBJETIVO GENERAL

El objetivo general de este proyecto es comparar el rendimiento de un agente inteligente en el juego Snake cuando compite contra jugadores reales. Para lograr este objetivo, utilizaremos el algoritmo de Deep Q-Learning para desarrollar el agente inteligente. El agente aprenderá desde cero, comenzando con movimientos aleatorios y adquirirá conocimiento para maximizar las recompensas según los estados posibles del juego.

El proceso de construcción del agente inteligente constará de varias etapas. En primer lugar, llevaremos a cabo un proceso de entrenamiento del agente, donde recopilaremos datos de las partidas del agente mientras aprende a jugar Snake. Estos datos serán utilizados para entrenar al agente utilizando el algoritmo de Deep Q-Learning, permitiendo que mejore su rendimiento a lo largo del tiempo.

Posteriormente, recolectaremos información de las partidas de jugadores reales que compiten en el juego Snake. Esta información será esencial para evaluar y comparar el rendimiento del agente inteligente frente a jugadores humanos experimentados.

En cuanto a la medición del rendimiento, definiremos aspectos específicos que nos permitan comparar el desempeño del agente inteligente con el de los jugadores humanos. Estos criterios podrían incluir la cantidad de puntos obtenidos, la duración de las partidas, la eficiencia en la recolección de recompensas y otros indicadores relevantes.

Es importante destacar que los datos recopilados de las partidas del agente inteligente también se utilizarán para mejorar su entrenamiento. Los registros de su progreso y aprendizaje

serán almacenados y utilizados para ajustar y perfeccionar el modelo del agente a lo largo del tiempo.

Al finalizar el proyecto, analizaremos los resultados obtenidos para extraer conclusiones significativas sobre la capacidad de los agentes inteligentes entrenados con Deep Q-Learning para competir en entornos de juego contra jugadores humanos. Este análisis proporcionará información valiosa sobre el potencial y las limitaciones de esta técnica de aprendizaje de refuerzo profundo en el contexto del juego Snake y podría tener aplicaciones más amplias en otros escenarios similares.

ANTECEDENTES

Como referencias para el presente trabajo de investigación, se encontraron trabajos y artículos que mencionan las aplicaciones prácticas sobre algoritmos de aprendizaje profundo sobre agentes de videojuegos.

Inicialmente, el artículo *A survey of deep reinforcement learning in video games* es una revisión sobre cómo se ha utilizado el *Deep Reinforcement Learning* en videojuegos [1]. Los autores exploran diversos enfoques y aplicaciones para entrenar agentes inteligentes capaces de jugar videojuegos de manera autónoma.

De forma similar, E. B. Montes Chaparro en su artículo “Inteligencia artificial adaptativa en videojuegos con procesos estocásticos” [2] explora agentes inteligentes que puedan ajustar su comportamiento y estrategias a medida que interactúan con el entorno de juego y adquieren experiencia por medio de recompensas y castigos.

D. Alcocer Soto en su publicación “Aprendizaje por refuerzo aplicado a los videojuegos cooperativos” [3] explora algoritmos de [?] para entrenar agentes inteligentes con el objetivo de que se comporten como compañeros cooperativos en el juego.

Igualmente, Mnih, V., Kavukcuoglu, K., Silver, D., Graves, A., Antonoglou, I., Wierstra, D., y Riedmiller, M. en su proyecto “Playing Atari with Deep Reinforcement Learning” [5], presentan un método en el que entrenaron un agente inteligente para jugar Atari utilizando únicamente la información visual de la pantalla y la puntuación del juego.

Por último, el trabajo “Estudio e implementación de Machine Learning en el desarrollo de videojuegos” publicado por J. D. Duarte Antolinez [4], se enfoca en cómo el *Machine Learning* puede ser utilizado de manera efectiva en el desarrollo de videojuegos para ofrecer una experiencia de juego más desafiante y realista.

METODOLOGÍA

Para la realización de los objetivos de este proyecto se va a llevar a cabo una metodología que consiste en 6 etapas de trabajo.

- **Definición y Construcción del Juego:** En la primera sección de la metodología se definirá e implementará un juego para el desarrollo del proyecto.




Figura 1. Etapas de la metodología de trabajo

- **Construcción del Agente Inteligente:** Una vez definido el ambiente de juego se implementará un agente inteligente para que funcione y aprenda sobre el juego previamente definido.
- **Entrenamiento y Recolección de Información del Agente:** Para el siguiente paso, teniendo el agente inteligente implementado, se plantea realizar el entrenamiento del agente inteligente. Esto se hace con la intención de que el agente logre desarrollarse sobre el juego. Después de entrenar al agente inteligente, se definirá los pasos para recolectar información que se obtendrán a partir de partidas evaluadas.
- **Recolectar Información de Partidas de Jugadores:** En esta sección, apartado del desarrollo de las 2 etapas anteriores, se recolectará información de partidas del juego previamente definido. Se definirá la forma en que se recolecta los resultados, obtenidos por medio de jugadores que interactúen con el juego.
- **Análisis de Resultados:** Finalmente, en esta etapa, se definirá como interpretar los datos que se obtienen, tanto del agente como de los jugadores.

REFERENCIAS

- [1] K. Shao, Z. Tang, Y. Zhu, N. Li, and D. Zhao, “A survey of deep reinforcement learning in video games,” *arXiv preprint arXiv:1912.10944*, 2019.
- [2] E. B. Montes Chaparro, “Inteligencia artificial adaptativa en videojuegos con procesos estocásticos,” 2014.
- [3] D. Alcocer Soto, “Aprendizaje por refuerzo aplicado a los videojuegos cooperativos,” B.S. thesis, Universitat Politècnica de Catalunya, 2018.
- [4] J. D. Duarte Antolinez, “Estudio e implementación de machine learning en el desarrollo de videojuegos,” 2019.
- [5] D. S. A. G. I. A. D. W. M. R. Volodymyr Mnih, Koray Kavukcuoglu, “Playing atari with deep reinforcement learning,” 2013.